

# Atividade de Fixação e Aprofundamento

edwillie@gmail.com [Mudar de conta](#)



Rascunho salvo.

\* Indica uma pergunta obrigatória

## Questões

Responda todas as questões.

Na atividade realizada no Orange, a matriz de confusão apresentou: 21 máquinas <sup>\*</sup> normais classificadas como normais; 2 máquinas normais classificadas como risco; 1 máquina em risco classificada como normal; e 16 máquinas em risco classificadas como risco. Qual interpretação é a mais adequada?

- ☐ O modelo obteve 97,5% de acurácia e seu único erro relevante foi classificar máquinas normais como risco.
- ☐ O modelo obteve 92,5% de acurácia e não apresentou falsos negativos.
- ☒ O modelo obteve 92,5% de acurácia, mas classificou uma máquina realmente em risco como normal, erro que pode ser particularmente crítico nesse cenário.
- ☐ Como foram identificados três erros, não é possível extrair nenhuma informação útil sobre o comportamento do modelo.

Considere três projetos: I) imagens de peças previamente classificadas como conforme ou defeituosa; II) dados de compras de clientes sem grupos previamente definidos; III) robô industrial que recebe recompensas ou penalidades conforme suas ações. Qual associação está correta? <sup>\*</sup>

- ☐ I - não supervisionado; II - por reforço; III - supervisionado.
- ☐ I - supervisionado; II - por reforço; III - supervisionado.
- ☒ I - supervisionado; II - não supervisionado; III - por reforço.
- ☐ I - por reforço; II - supervisionado; III - não supervisionado.



Durante o monitoramento de uma máquina, o sensor de vibração deixa de transmitir uma leitura. Um integrante da equipe sugere preencher imediatamente o campo com 0. Qual decisão é mais consistente com o que foi discutido? \*

- ☐ Zero é a melhor escolha porque permite que qualquer algoritmo processe o registro sem necessidade de pré-processamento.
- ☐ O registro deve sempre ser excluído, independentemente da quantidade de valores ausentes.
- ☒ Antes de substituir o valor, deve-se compreender a causa e o significado da ausência. Zero pode representar uma medição válida e, portanto, não deve ser automaticamente usado para representar um dado ausente.
- ☐ Todo valor ausente em sensores deve ser substituído pela média, pois essa estratégia não altera o comportamento dos dados.



No fluxo construído durante a aula foram utilizados Select Columns, Impute, Tree, \* Test & Score e Confusion Matrix. Explique o papel de cada um desses componentes no processo realizado. Explique também por que status foi definido como target e id\_maquina como meta, e não como atributo utilizado para realizar a previsão.

#### Impute

Trata valores ausentes (missing values) na base de dados. Algoritmos como a árvore de decisão podem ter problemas ou desempenho reduzido quando há células vazias. O Impute substitui esses valores ausentes por estimativas (média, mediana, valor mais frequente, um modelo preditivo simples, etc.), garantindo que o conjunto de dados esteja completo e utilizável antes do treinamento.

#### Tree (Árvore de Decisão)

É o algoritmo de aprendizado de máquina propriamente dito. Ele constrói um modelo em forma de árvore, dividindo os dados sucessivamente com base nos atributos mais informativos, até conseguir classificar as instâncias na classe alvo (no caso, status). É o "cérebro" que aprende os padrões dos dados.

#### Test & Score

Avalia o desempenho do(s) modelo(s) — nesse caso, a árvore de decisão — usando técnicas de validação (como validação cruzada ou divisão treino/teste). Ele calcula métricas como acurácia, precisão, recall, F1-score, AUC, entre outras, permitindo saber o quão bem o modelo generaliza para dados novos, e não apenas o quanto "decorou" os dados de treino.

#### Confusion Matrix

Mostra de forma detalhada os acertos e erros do modelo, comparando as classes reais com as classes previstas. Permite visualizar, por exemplo, quantos casos de uma máquina em falha foram corretamente identificados, quantos falsos positivos e falsos negativos ocorreram — informação mais granular do que apenas a acurácia geral.



Se conceitos de Inteligência Artificial existem há décadas, qual explicação apresentada na aula melhor justifica a forte expansão das aplicações nos últimos 10 a 15 anos? \*

- ☐ O principal fator foi apenas o aumento da velocidade dos processadores tradicionais, independentemente de dados e algoritmos.
- ☐ A expansão resulta da combinação entre grande disponibilidade de dados, maior poder computacional - incluindo GPUs e nuvem - e amadurecimento dos algoritmos, especialmente de Deep Learning.
- ☐ O fator determinante foi exclusivamente o surgimento dos modelos de linguagem generativa.
- ☐ A criação do termo Inteligência Artificial em Dartmouth só passou a ter validade prática após 2010.

Uma equipe está desenvolvendo um sistema baseado em uma rede neural profunda para analisar imagens. Um integrante afirma: "Como utilizamos Deep Learning, esse projeto não utiliza Machine Learning; são abordagens diferentes dentro da Inteligência Artificial." Qual análise está correta? \*

- ☐ A afirmação está correta apenas quando os dados utilizados são imagens, voz ou texto.
- ☐ A afirmação está correta, pois Machine Learning e Deep Learning são duas áreas independentes da Inteligência Artificial.
- ☐ A afirmação está incorreta porque todo sistema de Inteligência Artificial necessariamente utiliza Deep Learning.
- ☐ A afirmação está incorreta: Deep Learning é uma subárea de Machine Learning, que, por sua vez, está inserido no campo mais amplo da Inteligência Artificial.

Uma indústria pretende construir um sistema para antecipar falhas de motores utilizando temperatura, vibração, corrente elétrica, horas de operação e histórico de falhas. Descreva como você organizaria esse problema nas cinco etapas: seleção, pré-processamento, transformação, mineração e interpretação. Apresente pelo menos uma decisão concreta em cada etapa e explique uma situação em que o resultado faria você retornar a uma etapa anterior. \*

Sua resposta



Com base no artigo de Fayyad, Piatetsky-Shapiro e Smyth (1996), explique a diferença entre KDD e data mining. Explique também por que seleção, preparação, limpeza e interpretação dos dados são relevantes e o que significa afirmar que o processo de KDD é interativo e iterativo. \*

#### Diferença entre KDD e Data Mining

\* KDD (Knowledge Discovery in Databases) é o processo completo de descoberta de conhecimento útil a partir de dados. Ele engloba desde a compreensão do domínio de aplicação, passando pela seleção e preparação dos dados, até a interpretação final dos resultados e o uso do conhecimento gerado. É um processo amplo, de várias etapas, não-trivial, interativo e iterativo.

\* Data mining é apenas uma etapa dentro do processo de KDD — especificamente, a aplicação de algoritmos específicos para extrair padrões (ou modelos) dos dados já preparados. É a fase "algorítmica" de busca de padrões, mas não o processo inteiro.

#### Por que seleção, preparação, limpeza e interpretação são relevantes

Essas etapas são cruciais porque, segundo o artigo, a maior parte do trabalho prático em KDD não está na mineração em si, mas em garantir que os dados de entrada sejam adequados e que os resultados façam sentido:

Sem essas etapas, mesmo o melhor algoritmo de mineração pode produzir resultados enganosos, estatisticamente inválidos ou incompreensíveis — o próprio artigo destaca que "lixo entra, lixo sai" é um risco real quando essas fases são negligenciadas.

#### O que significa o processo ser "interativo e iterativo"

\* Iterativo: as etapas do KDD (aprendizado do domínio, seleção, limpeza, transformação, mineração, interpretação, uso do conhecimento) não seguem necessariamente uma sequência linear única. Pode haver retorno (loops) entre quaisquer duas etapas.

\* Interativo: o processo depende fortemente de decisões humanas ao longo de todas as etapas.



Na prática realizada, status foi definido como variável-alvo, id\_maquina foi mantido como metadado e a árvore encontrou uma divisão utilizando um dos atributos dos equipamentos. Qual interpretação é a mais adequada? \*

- ☐ O algoritmo inferiu divisões a partir dos exemplos históricos; status forneceu as classes que deveriam ser aprendidas e id\_maquina não foi utilizado como variável preditiva.
- ☐ O identificador da máquina deveria necessariamente participar da previsão, pois todo atributo disponível melhora um modelo.
- ☐ A regra apresentada pela árvore foi previamente escrita no Orange e apenas aplicada aos dados carregados.
- ☐ Status foi utilizado como entrada para prever os próprios valores de status, razão pela qual a árvore apresentou boa acurácia.

Uma fábrica possui centenas de sensores instalados em seus equipamentos. Eles registram continuamente temperatura, vibração, corrente elétrica e outras variáveis. A empresa pretende utilizar esses registros para antecipar falhas. Qual sequência representa melhor a relação apresentada em aula entre IoT, Big Data e Inteligência Artificial? \*

- ☐ Big Data produz os dados dos sensores; Inteligência Artificial os armazena; IoT escolhe o algoritmo.
- ☐ IoT realiza o sensoriamento e gera dados; a infraestrutura de dados armazena e organiza esses registros; algoritmos de Inteligência Artificial analisam os dados para apoiar ou automatizar decisões.
- ☐ A Inteligência Artificial coleta fisicamente os dados; IoT identifica padrões; Big Data toma a decisão final.
- ☐ IoT realiza a previsão; Inteligência Artificial registra os resultados; Big Data atua apenas quando ocorre uma falha.

[Voltar](#)[Enviar](#)Página 2 de 2 [Limpar formulário](#)

Nunca envie senhas pelo Google Formulários.

Este conteúdo não foi criado nem aprovado pelo Google. - [Entre em contato com o proprietário do formulário](#) - [Termos de Serviço](#) - [Política de Privacidade](#)

Este formulário parece suspeito? [Denunciar](#)



Google Formulários

